

一個影像式多語意模組融合的交通風險評估 與主動安全預警框架

¹ 林武杰、² 蔡承廷、³ 劉康申、⁴ 謝宏喆

^{1,2,3,4} Department of Computer Science and Information Engineering,
National Formosa University, Yunlin County, Taiwan

¹wjlin@nfu.edu.tw、²tsai0822justin@gmail.com、³qaz33145@gmail.com、⁴jeff940130@gmail.com

摘要

道路監視影像可提供低成本交通觀測，但交通風險常由超速、闖紅燈、異常軌跡與多車互動共同形成，單一違規偵測難以穩定預警。本研究提出影像式多語意融合框架，結合車輛偵測與追蹤、道路幾何、單一車輛與場景風險評估，輸出無風險、中風險與高風險三級預警。實驗顯示，單一車輛與場景風險模組皆具可用的風險評估表現。

關鍵字：影像式交通分析、主動安全預警、多語意融合、單一車輛風險、場景風險、GRU。

1. 緒論

影像式交通風險評估常以車輛偵測、追蹤與特定違規行為判斷為基礎。然而，主動安全預警所面對的問題並不只是判斷「某一種違規是否發生」，而是判斷「當前交通狀態是否有危險，應提醒行人與周邊用路人提高警覺」。例如，一台車可能先出現逆向或蛇行等軌跡異常，接著又在紅燈期間進入路口。也可能單一車輛本身只有中風險，但因為與其他車輛形成接近或交會趨勢，使整體場景安全必須提升為高風險。這類情境顯示，單一違規偵測不足以反映通行風險。

多語意模組融合因此成為必要設計。本研究稱多語意，是指由不同交通行為來源形成的風險資訊，包含超速、闖紅燈、異常軌跡與多車互動。超速、闖紅燈與異常軌跡分別描述不同風險來源：速度反映車輛相對於法定速限的行駛狀態、接近速度與煞停空間，號誌反映路口通行權衝突，軌跡反映車輛是否偏離道路幾何與正常行駛方向。若僅使用其中一種訊號，系統可能無法分辨短暫雜訊與真正危險。若完全由單一分類器直接輸出警示，則較難向使用者或研究者說明警示來源。因此，本研究將「可解釋的交通行為訊號」與「時間序列模型」結合，使模型能學習連續行為，同時做完整通行風險評估。

道路場景幾何建模也是本研究的重要基礎。車輛在影像中的位移必須結合車道方向、有效偵測區域、逆透視轉換與虛擬停止線等道路條件，才可判斷其是否逆向、是否越線、速度估計是否可靠，以及是否可能與其他車輛發生碰撞。換言之，本研究不是僅使用車輛偵測框進行分類，而是將偵測結果轉換成具有道路幾何與交通規則意義的風險評估。

本研究提出一個影像式多語意模組融合的交通風險評估與主動安全預警。本研究稱交通風險，並非僅指已發生碰撞或單一違規，而是指當前影像中已出

現足以觸發警示的交通狀態。系統首先由道路監視影像取得車輛偵測與追蹤結果，再透過超速、闖紅燈與異常軌跡分析取得多種交通語意。其後，風險融合評估模組分為兩個層級：(1) 單一車輛風險模組判斷每台車隨時間形成的風險，(2) 場景風險模組進一步整合多台車、場景統計與車對車互動，輸出整體場景警示。此設計可將「單一車輛本身風險」與「整體場景是否需要提高警示」區分開來，避免把場景風險簡化為單一車輛分類結果。

本研究稱主動安全預警，並非對行人位置進行追蹤後才發出警示，而是將偵測點附近可能出現的危險車輛轉換為周邊用路人可理解的警示等級。也就是說，系統的核心任務不是判斷某一名行人是否即將碰撞，而是在危險車輛接近或多車互動風險形成時，及早提供用路人「注意」或「停止通行」等警示。本研究重視風險起始時間，目標是在多項異常或多車互動風險形成時及早提出警示，而不是事後辨識單一違規事件。

本研究主要貢獻如下：

- 提出一個整合超速、闖紅燈與異常軌跡的多語意交通風險評估框架。
- 提出車輛風險評估模組，使用 16 維語意時間序列特徵、GRU 與交通語意規則，評估車輛險：高、中、低。
- 提出場景風險模組，整合多個車輛風險、評估場景統計與車對車互動，使整體場景可高於單一車輛的獨立行為風險。
- 以固定切分與 video-level 5-fold 評估分析系統表現，討論預警起點、window 邊界與中風險類別對評估結果的影響。

2. 相關研究

影像式交通分析通常以物件偵測與多目標追蹤作為前端。YOLO 類偵測器常用於即時影像處理 [1, 2]，Deep SORT 與 ByteTrack 則分別透過外觀特徵或高低信心偵測框關聯維持車輛追蹤 ID [3, 4]。這些方法可回答「車在哪裡」與「是否為同一台車」，但不直接判斷是否需要發出安全警示。

交通異常偵測研究常以軌跡或行為模式辨識非典型事件 [5, 6]，近年亦使用深度學習模型辨識事故或異常事件 [7, 8]。然而，若缺少道路幾何、號誌與速度語意，較難將異常轉換為分級式預警。

交通安全評估亦常使用 TTC (Time-to-Collision，用

來估計兩物體多久後可能接近或碰撞的時間指標) 等替代安全指標 [9]，並可由影片式交通衝突分析評估路口安全 [10]。這類指標能描述車輛間互動風險，但若單獨使用，可能忽略紅燈、逆向或超速等交通規則語意。

在時間序列建模方面，GRU 可整合連續觀測中的累積資訊 [11]，但若只依賴時序神經網路，模型輸出較難對應交通規則與預警理由。綜合而言，既有方法多半聚焦於偵測追蹤、軌跡異常、交通衝突或事故辨識等單一任務。本研究則進一步結合道路幾何、號誌狀態、速度、軌跡異常與多車互動，將個別交通行為訊號轉換為可分級、可解釋且可用於主動警示的風險輸出。

3. 研究方法

3.1 系統整體架構

圖1為系統整體架構。輸入影像先經由車輛偵測與追蹤取得每台車的位置與追蹤 ID，再由道路場景幾何建模提供車道方向、有效偵測區域、逆透視轉換與虛擬停止線等資訊。多語意交通行為分析接著判斷超速、闖紅燈與異常軌跡，最後，風險融合評估模組分別輸出單一車輛風險與整體場景風險，並將輸出分為無風險、中風險與高風險三種預警等級。




圖 1. 系統整體架構圖

此流程的設計重點在於逐層提高語意層次：車輛偵測與追蹤提供「車輛在哪裡、如何移動」，道路幾何將其對應至車道、停止線與可通行區域，多語意交通行為分析再將其轉換為超速、闖紅燈與異常軌跡等判斷結果。最後才由風險融合評估模組決定是否需要對周邊用路人發出警示。透過分層設計，最終警示不僅是分類結果，也能回溯至超速、闖紅燈、異常軌跡或多車互動等交通語意來源。

3.2 影像前端：車輛偵測、追蹤與號誌辨識

影像前端負責將連續道路影像轉換為結構化資料。本研究使用 YOLO 逐幀偵測車輛 [1, 2]，取得邊界框、類別與信心分數，再以 ByteTrack 追蹤同一台車在連續幀中的目標身分 [4]，使每台車可形成獨立的時間序列軌跡，輸出資料包含幀編號、track ID、邊界框座標、偵測信心與類別，作為速度估計、軌跡分析與風險評估的基本資訊。

除車輛軌跡外，本研究使用固定號誌 ROI 搭配輕量 CNN 辨識紅綠燈狀態。固定 ROI 由場景設定檔指定，對應影像中號誌所在區域；每幀號誌狀態及信心分數會寫入車輛軌跡資料，使闖紅燈判斷可同時使用車輛位置與號誌資訊。

實作中，車輛偵測使用輸入解析度 1280、信心門檻 0.18 與 IoU 門檻 0.55；號誌辨識使用固定 ROI，分類信心門檻為 0.55。這些參數並非風險模型輸入特徵，但會影響後續軌跡、速度與闖紅燈判斷，因此實驗中固定不變。

3.3 道路場景幾何建模

道路場景幾何建模用於補足影像座標缺乏道路方向與車道規則的問題。相同的偵測框位移，在不同車道方向或影像區域中可能代表正常行駛、逆向、轉彎或投影誤差。因此，本研究使用車道區域與方向、有效偵測區域、逆透視轉換與虛擬停止線作為輔助資訊。有效偵測區域指系統允許進行速度、軌跡與互動判斷的影像範圍，用於排除影像邊緣與透視誤差較大的區域。

逆透視轉換 (Inverse Perspective Mapping, IPM) 將影像中的車輛位置近似轉換至地面平面座標，用於估計速度與相對距離。若 $\mathbf{p}_t$ 表示車輛在地面平面上的位置，且座標已換算為公尺，則相鄰時間點速度可由

$$v_t = \frac{\|\mathbf{p}_t - \mathbf{p}_{t-1}\|}{\Delta t} \times 3.6 \quad (1)$$

估計，其中 Δt 為時間差， v_t 單位為 km/h。式中的 3.6 為單位換算係數，將公尺/秒轉換為公里/小時。有效偵測區域與偵測框穩定性則用於降低影像邊緣、遠距車輛框面積過小與短暫遮擋對速度與互動判斷的影響。

車道區域與方向用於判斷車輛運動是否符合道路方向與車道規則，例如是否逆向、是否出現不符合車道方向的轉換，以及是否屬於正常轉彎或單次變道。虛擬停止線則用於判斷車輛是否在紅燈期間跨越停止線，或輔助判斷車輛在紅燈期間位於交叉路口內時，是否仍持續產生前進位移。這些幾何資訊不直接等同於最終風險，而是轉換為超速、闖紅燈與異常軌跡等語意資訊。

3.4 時間窗與風險等級

本研究使用兩種時間窗，單一車輛風險模組以每台車的追蹤序列建立 ID window，用於描述同一台車在一段時間內的變化，場景風險模組則以全域時間建立 scene window，用於描述同一時間區間內所有車輛與整體場景狀態，時間窗以幀數建立，並依輸入影像

序列的 FPS 換算；若影像序列幀率為 f_{fps} ，每窗約包含 $\text{round}(0.667f_{\text{fps}})$ 幀，滑動間隔約為 $\text{round}(0.333f_{\text{fps}})$ 幀。以 30 fps 影片為例，約為 20 幀與 10 幀。

ID window 以車輛出現後的追蹤序列為起點，scene window 以影片全域時間為起點，因此同一事件可能落在相鄰 window。當兩者邊界不完全重合時，本研究僅使用已完成的單一車輛 window 進行對齊，避免場景模組提前使用尚未完成的車輛資訊。

場景風險警示採三等級輸出：(1) 無風險，表示未偵測到需警示的明確異常，(2) 中風險，表示已有違規或異常語意，應提醒用路人注意；(3) 高風險，表示存在嚴重異常、多項異常或明確交會危險，應觸發更強警示。

3.5 多語意交通行為分析

多語意交通行為分析將偵測框與追蹤軌跡轉換為可解釋的交通行為資訊，而不是直接以原始座標判斷最終風險。本研究將交通行為分析分為超速、闖紅燈與異常軌跡三類。三個模組皆以車輛追蹤結果、時間戳與道路幾何資訊為基礎，輸出以時間窗為單位的異常強度、判定結果與訊號穩定性，再交由單一車輛風險模組進行時間序列融合。表 1 摘要三類分析項目的主要輸入與輸出。

表 1. 多語意交通行為分析輸入與輸出摘要

分析項目	主要輸入	輸出
超速	IPM 座標、時間戳、速度序列與偵測框穩定性	速度高分位數、連續超速、速度可靠度與超速強度
闖紅燈	號誌狀態、停止線與車輛軌跡	停止線跨越、交叉路口內前進與闖紅燈強度
異常軌跡	軌跡特徵、GMM 異常分數、車道區域與方向	正常軌跡偏離程度、逆向、蛇行與壓線訊號

3.5.1 超速

超速判斷以逆透視轉換後的地面座標位移估計速度；此處的地面座標是指將影像中的車輛位置投影至道路平面後得到的位置。系統並在每個時間窗內彙整速度高分位數（如第 95 百分位速度）、平滑速度、窗內超速比例、連續超速幀數、原始速度與平滑速度差距，以及偵測框穩定性。偵測框穩定性包含偵測信心、框面積變化、中心位置跳動、影像中面積過小的遠距車輛框與遮擋情形；若顯示偵測不穩，單一或少數幀的速度突然升高不直接作為超速判斷。中度且速度訊號穩定的超速主要判定為中風險；若速度已穩定達到高風險區間，或與闖紅燈、逆向、蛇行等異常同時出現，才判定為高風險。

3.5.2 闖紅燈

闖紅燈判斷使用號誌狀態、虛擬停止線與車輛軌跡。最直接的違規情況是車輛在紅燈期間跨越停止線，且跨越後仍有前進位移。若車輛進入畫面時已位於兩條停止線之間，系統會檢查紅燈期間是否仍持續前進；若車輛是在綠燈時已進入該範圍，之後因排隊、轉彎

等待或清空路口而短暫移動，則不判定為闖紅燈。只有在紅燈期間仍持續前進，且不符合合法進入情況時，才判定為闖紅燈並列為中風險。

3.5.3 異常軌跡

異常軌跡判斷描述車輛路徑是否符合道路方向與車道規則，主要包含逆向、蛇行、壓雙黃線或不符合車道規則的轉換。此模組的基礎為 GMM (Gaussian Mixture Model, 高斯混合模型) [12]。實作中，系統將每個時間窗內的位置、速度、加速度、方向變化、車道方向一致性與邊界框動態整理為 47 維軌跡特徵，並以約 8 小時正常車流影片中的車輛軌跡建立常見行駛型態的機率分布。此處的正常分布是正常行駛行為的基準分布，並非假設所有軌跡都服從單一常態分布。

GMM 由 10 個高斯分布子模型組成，可理解為 10 種正常行駛型態的統計描述；每個子模型皆使用完整共變異矩陣，以描述軌跡特徵間的相關變化。可用於建立正常行駛分布的 window 約 55.9 萬筆，訓練時抽取 20 萬筆建立模型。異常門檻由正常資料的高分位分布設定，並使用平滑係數 0.7 的時間平滑降低單窗異常高值，使 GMM 輸出「偏離正常車流的程度」。

由於 GMM 異常分數仍可能受到遮擋、偵測框抖動或轉彎區域影響，本研究不直接以單一時間窗分數決定風險，而會結合時間平滑、局部歷史、車道區域、車道方向、車輛運動方向與追蹤穩定性，判斷是否為逆向、蛇行、壓雙黃線或不符合車道規則的轉換。因此，系統會區分「正常轉彎或單次變道」與「反覆變道或蛇行」，也會區分「短暫壓線」與「明確進入對向或持續逆向」。單純逆向、蛇行或壓雙黃線通常歸類為中風險；若同時出現闖紅燈、穩定超速或其他類型異常，才列入高風險。

三類交通行為分析完成後，系統將其視為互補的風險資訊：超速描述車輛相對於法定速限的行駛狀態、接近速度與煞停空間，闖紅燈描述號誌通行權衝突，異常軌跡描述是否偏離合理道路路徑。單一異常通常先判定為中風險；多種異常連續或同時成立時，才判定為高風險。

3.6 風險融合評估模組

風險融合評估模組將前述交通行為判斷轉換為穩定且可解釋的預警等級。若任一語意都可直接觸發警示，系統易受短暫雜訊影響。若只依賴單一分類器直接輸出風險，則較難說明警示原因。因此本研究採兩層設計：單一車輛風險模組描述每台車的時間序列風險，場景風險模組描述同一時間區間內多車狀態與互動造成的整體警示需求。

3.6.1 單一車輛風險模組

單一車輛風險模組以每台車的 ID window 為單位，輸入為多語意交通行為分析模組壓縮後的 16 維時間序列特徵。這些特徵可分為四個群組：異常軌跡、超速、闖紅燈相關資訊，以及多語意時間資訊。圖 2 顯示此模組由特徵標準化、GRU 時序模型、語意風險規則（依交通行為判定調整風險等級的後處理）與累積式輸出組成；表 2 列出 16 個輸入特徵的語意名稱、型態與用途。




圖 2. 單一車輛風險模組架構圖

表 2. 單一車輛風險模組 16 維輸入特徵表

編號	語意特徵	資料型態	用途
f1	確認軌跡異常	二元, 0/1	已確認逆向、蛇行或軌跡異常, 抑制單窗抖動。
f2	軌跡異常持續程度	float [0,1]	描述異常軌跡訊號是否逐漸穩定。
f3	時間窗軌跡異常強度	float [0,1]	表示該時間窗的逆向、蛇行或軌跡異常強度。
f4	中度超速程度	float [0,1]	判斷超速是否足以形成中風險。
f5	超速連續程度	float [0,1]	區分連續超速與單一速度突增。
f6	速度穩定性	float [0,1]	降低偵測框抖動、IPM 邊界與遠距車輛框面積過小造成的速度誤差。
f7	可信超速判斷	float [0,1]	超速明確且速度估計可靠時分數較高, 速度不穩定時分數較低。
f8	時間窗超速強度	float [0,1]	超速模組輸出的該時間窗事件強度。
f9	時間窗闖紅燈強度	float [0,1]	該時間窗闖紅燈事件強度。
f10	當窗異常類型數	int [0,3]	計算該時間窗內成立的異常類型數量。
f11	異常重疊程度	float [0,1]	表示多類異常在同一窗或相鄰窗出現的程度。
f12	車輛已觀測時間	float [0,1]	表示車輛自首次被追蹤至目前時間窗, 已被觀測多久。
f13	紅燈時路口內前進	二元, 0/1	紅燈期間已在交叉路口內仍持續前進。
f14	闖紅燈且逆向	二元, 0/1	紅燈與明確逆向同時成立。
f15	闖紅燈與異常軌跡	float [0,1]	闖紅燈與蛇行或逆向同時成立的程度。
f16	明確蛇行	二元, 0/1	區分正常變道與反覆擺動。

表中所有特徵皆來自多語意交通行為分析模組與道路幾何設定, 不直接使用原始影像像素。其中 f1–f3 與 f16 對應異常軌跡, f4–f8 對應超速, f9 與 f13–f15 對應闖紅燈相關資訊, f10–f12 則描述多種異常是否同時成立與車輛所處時間階段。此設計讓模型接收已具交通意義的時間序列資訊, GRU 主要學習這些資訊隨時間演化並累積成風險的過程, 而不是直接由影像像素或大量座標學習交通規則。

下列計算式說明超速、闖紅燈與異常軌跡三項交通行為資訊的主要轉換原理; 實際判斷時, 系統仍會檢查連續幀、偵測框穩定性、道路區域與遮擋情形。

超速以時間窗內超過速限門檻的幀比例表示:

$$\rho_{\text{speed}} = \frac{1}{N} \sum_{i=1}^N \mathbf{1}(v_i - v_{\text{limit}} \geq \theta), \quad (2)$$

其中 N 為時間窗內幀數, v_i 為第 i 幀的估計速度, v_{limit} 為速限, θ 為超速門檻。實際超速特徵另參考速度高分位數、連續超速幀數、平滑速度與偵測框穩定性。

闖紅燈以紅燈期間車輛跨越停止線, 或已在交叉路口內仍持續前進的幀比例表示:

$$\rho_{\text{redmove}} = \frac{1}{N} \sum_{i=1}^N r_i m_i, \quad (3)$$

$$I_{\text{red}} = \mathbf{1}(\rho_{\text{redmove}} \geq \tau_{\text{red}})(1 - E_{\text{green}}).$$

其中 r_i 表示第 i 幀是否為紅燈, m_i 表示該幀是否出現停止線跨越或交叉路口內前進, τ_{red} 為闖紅燈比例門檻。 $E_{\text{green}} = 1$ 表示車輛已在綠燈時合法進入交叉路口, 因此不將後續清空路口的移動判定為闖紅燈; 此式不表示車輛只要位於交叉路口內且號誌為紅燈就必然違規。

異常軌跡先以 GMM 描述正常車流的軌跡分布, 再將與正常分布的偏離程度轉為異常分數:

$$p(\phi_t) = \sum_{m=1}^M \pi_m \mathcal{N}(\phi_t; \mu_m, \Sigma_m), \quad (4)$$

$$A_t = \lambda A_{t-1} + (1 - \lambda) \text{norm}(-\log p(\phi_t)).$$

其中 ϕ_t 為第 t 個 ID window 的軌跡特徵, M 為 GMM 中高斯分布子模型的數量, π_m 、 μ_m 與 Σ_m 分別為第 m 個子模型的權重、平均向量與共變異矩陣。 $\text{norm}(\cdot)$ 表示依正常資料分布縮放至 0–1, A_t 為經時間平滑後的異常軌跡分數。GMM 分數只衡量軌跡偏離正常車流的程度; 最終特徵仍會結合車道方向、車輛運動方向、持續性檢查與遮擋排除。

依前述特徵定義完成每個 ID window 的 16 維向量後, 將第 t 個 ID window 的輸入向量表示為 $\mathbf{x}_t \in \mathbb{R}^{16}$ 。GRU 用於建模車輛行為隨時間演化的風險狀態:

$$\mathbf{z}_t = \sigma(W_z \mathbf{x}_t + U_z \mathbf{h}_{t-1}), \quad (5)$$

$$\mathbf{r}_t = \sigma(W_r \mathbf{x}_t + U_r \mathbf{h}_{t-1}), \quad (6)$$

$$\tilde{\mathbf{h}}_t = \tanh(W_h \mathbf{x}_t + U_h (\mathbf{r}_t \odot \mathbf{h}_{t-1})), \quad (7)$$

$$\mathbf{h}_t = (1 - \mathbf{z}_t) \odot \mathbf{h}_{t-1} + \mathbf{z}_t \odot \tilde{\mathbf{h}}_t. \quad (8)$$

為簡化表示, 式中省略偏置項。其中 $\mathbf{z}_t$ 為更新門、 $\mathbf{r}_t$ 為重置門、 $\mathbf{h}_t$ 為時間記憶狀態, σ 為 sigmoid 函數。分類層將隱藏狀態 $\mathbf{h}_t$ 映射為未正規化分類分數 (logits) $\mathbf{o}_t$, 再以 softmax 轉為三類風險機率:

$$P(y = k | \mathbf{x}_{1:t}) = \frac{\exp(o_{t,k})}{\sum_j \exp(o_{t,j})}. \quad (9)$$

本研究採用的 GRU 設定為單層、隱藏維度 64、dropout (隨機失活) 0.1, 輸出為三個預警等級。訓練

時使用 focal loss (降低大量正常樣本主導訓練的損失函數) 以減少類別不平衡影響 [13]，並以 val (validation set, 驗證集) 的 Macro F1 (各類別平均 F1) 選擇最佳模型 [14]。訓練設定固定為 learning rate (學習率) 0.0005、batch size (批次大小) 32、最多 25 個 epochs (訓練輪數)、early stopping patience (未改善容忍輪數) 5 [15]，並使用梯度裁切避免訓練不穩定。所有固定切片與 video-level 5-fold 實驗均維持相同模型架構與訓練設定，只改變資料切片，且每一 fold 僅以 train 資料計算標準化參數。

為便於對照表2的模型輸入與前述計算式，表3彙整 16 維特徵如何由超速、闖紅燈、異常軌跡與時間脈絡轉換而來。

表 3. 單一車輛風險模組 16 維特徵計算方式摘要

編號	計算方式摘要
f1	同一 track 內連續判定為逆向、蛇行或偏離合理路徑，且已排除正常轉彎與遮擋時設為 1。
f2	取 GMM 異常分數、車道方向差與近期位移變化，經時間平滑後縮放到 0-1，數值越高表示異常軌跡越穩定。
f3	由該時間窗的逆向比例、蛇行分數與路徑偏離量計算，取其中較強者作為軌跡異常強度。
f4	依速度高分位數、超過速限門檻的比例與式 (2) 計算，數值越高表示越接近中風險超速。
f5	統計本窗與先前相鄰窗中，速度連續超過門檻的幀比例與最長連續幀數。
f6	檢查偵測框面積與位置是否穩定，並比較原始速度與平滑速度差距，降低影像邊緣或遠距小車框造成的速度誤差。
f7	由 f4 與 f6 共同計算；超速明確且速度可靠時分數較高，速度不穩定時分數較低。
f8	整合該時間窗的速度高分位數、連續超速幀數與 f6，形成超速事件強度。
f9	依號誌狀態、停止線位置、紅燈期間前進距離，以及交叉路口內是否仍前進計算。
f10	加總超速、闖紅燈與異常軌跡三類判定，表示當窗成立幾類異常，範圍為 0-3。
f11	檢查三類異常是否在同一窗或相鄰窗出現，並依重疊程度縮放到 0-1。
f12	由已觀測時間 d_t 與時間尺度參數 τ 計算 $1 - \exp(-d_t/\tau)$ ，表示車輛已被追蹤多久；不需知道 track 結束時間。
f13	紅燈期間車輛已位於交叉路口內，且仍持續產生前進位移時設為 1。
f14	闖紅燈與明確逆向在同一窗或相鄰窗同時成立時設為 1。
f15	由 f9 與軌跡異常強度共同計算，表示闖紅燈同時伴隨蛇行或逆向的程度。
f16	由車道序列與橫向位移判斷是否反覆變道，並排除正常轉彎、單次變道與短暫遮擋。

3.6.2 語意風險規則與穩定化

GRU 輸出後並非直接作為最終風險，而是再經過語意風險規則。語意風險規則是指依據超速、闖紅燈與異常軌跡的判定結果，對模型輸出的風險等級進行限制、升級或保留的後處理規則。穩定化是指排除單一時間窗的短暫抖動，並要求連續超速、明確逆向、持續蛇行或已確認闖紅燈等交通行為訊號足夠穩定後，才允許風險升級。

此規則的目的不是取代模型，而是使模型輸出符合人工標註時採用的交通風險定義：單純逆向或蛇行通常判定為中風險；闖紅燈加逆向、闖紅燈加蛇行、逆向加穩定超速，或穩定高速，才歸類為高風險。若模型因短暫偵測抖動而傾向升級，但缺乏前述交通行為訊號，最終輸出會被限制在已確認交通行為所對應

的風險等級；若已出現明確闖紅燈、逆向或穩定超速訊號，語意規則則可將風險等級提升至中風險或高風險。

語意風險規則之後，單一車輛風險採用累積式輸出。此規則只針對同一台車的同一條 track 更新風險狀態，不會改變同一 scene window 中其他車輛的風險。令第 i 台車在第 t 個 ID window 的該時間窗風險為 $R_{i,t}^{\text{window}}$ ，對外輸出的單一車輛風險為 $R_{i,t}^{\text{track}}$ ，則

$$R_{i,t}^{\text{track}} = \max(R_{i,t-1}^{\text{track}}, R_{i,t}^{\text{window}}), \quad (10)$$

此設計符合主動預警情境：當同一台車已被確認具有較高風險，代表該車曾出現對周邊車輛或行人較不安全的行為。即使後續短時間內未再觀察到明顯異常，該車仍應維持較高注意等級，不宜立即降回無風險。同時，累積式輸出也可避免警示因短暫訊號下降而在短時間內反覆跳動。此累積策略僅作用於該車輛 track 的生命週期內。當車輛離開有效偵測區域或 track 結束後，該車輛風險狀態即被重置。

3.7 場景風險模組

單一車輛風險模組回答「某一台車是否危險」，場景風險模組則回答「當前整體畫面是否需要提高警示」。兩者不完全等價：一台高風險車輛足以提高整體場景警示，而多台中風險車輛若形成接近或交會趨勢，也可能使場景升級。因此，場景風險不是所有車輛風險的平均，而是整合單一車輛風險、場景統計與多車互動後的判斷。圖3整理場景模組的主要資料流與融合方式。




圖 3. 場景風險模組架構圖

每個 scene window 會收集該全域時間窗內可取得的車輛狀態，包含車輛是否仍在畫面中、單一車輛風險與交通行為分析結果。此處的「已完成對齊」是指某台車的 ID window 已完成計算，且可在目前 scene window 使用；尚未完成的 ID window 不會被場景模組使用，以避免使用未來影格。場景模組會將每台保留車輛轉換為固定長度的車輛摘要向量 (token)。此處的 token 並非文字 token，而是一台車在該 scene window 中的數值特徵列。其內容包含單一車輛最終風險、單一車輛風險模組對無風險、中風險與高風險的輸出機率、超速強度、闖紅燈強度、異常軌跡強度，以及同一時

間窗內多種異常同時成立的程度。實作上每個 scene window 最多保留 16 個車輛摘要向量；若車輛數不足，會以空白向量補齊。有效車輛標記 (mask) 用 1 表示實際車輛、0 表示補齊用的空白位置，池化時只計算實際車輛，不計算空白位置。同時，系統建立場景統計特徵，例如該時間窗內的車輛數、最高單一車輛風險、最高超速或違規強度，以及前幾個 scene window 的場景風險等級。

此設計使場景模組能同時觀察少數高風險車輛與整體交通狀態。若僅使用整體場景平均特徵，容易稀釋少數高風險車輛；若只看單一最高風險，又會忽略多車互動。因此，本研究同時使用車輛摘要向量與場景統計特徵。

本研究的場景風險模組並非直接套用現成分類模型，而是依交通場景預警需求設計的輕量化雙分支網路。車輛摘要向量在同一個 scene window 中沒有固定順序，且不同時間窗的車輛數量也不相同，因此車輛摘要分支採用集合資料模型常見的排列不變聚合概念 [16, 17]，也就是車輛排列順序改變時，場景表示不應改變。在本研究中，最大池化與平均池化用於車輛摘要分支，將多台車的摘要向量合併為單一場景表示。若第 i 台車的摘要編碼為 $\mathbf{e}_i = [e_{i,1}, \dots, e_{i,d}]$ ，其中 d 為摘要維度， $\mathcal{I}_s$ 為 scene window s 中標記為有效的車輛集合， $N_s = |\mathcal{I}_s|$ ，則最大池化與平均池化皆以各維度分別計算：

$$\begin{aligned} \mathbf{p}_{\max,k} &= \max_{i \in \mathcal{I}_s} e_{i,k}, \\ \mathbf{p}_{\text{avg},k} &= \frac{1}{N_s} \sum_{i \in \mathcal{I}_s} e_{i,k}, \quad k = 1, \dots, d. \end{aligned} \quad (11)$$

最後將兩個池化結果串接為 $\mathbf{p} = [\mathbf{p}_{\max}, \mathbf{p}_{\text{avg}}]$ 。也就是說，最大池化不是對整個向量取單一最大值，而是在每一個特徵維度上取所有車輛中的最大值，用來保留該時間窗中最明顯的風險特徵；平均池化則描述整體交通狀態。池化後的車輛摘要表示再與場景統計特徵結合，輸出三類場景風險。

模型結構包含車輛摘要分支與場景統計分支。車輛摘要分支先將每台車的摘要向量轉換為隱藏表示，場景統計分支則處理車輛數、最高風險與近期場景狀態等統計特徵，兩者融合後輸出場景風險。兩個分支隱藏維度均為 64，融合層隱藏維度為 96。訓練時 batch size 為 256，learning rate 為 0.001，最多訓練 80 個 epochs，並以 val 的嚴重度 Macro F1 選擇模型權重 [14]。

場景模組另使用車對車互動特徵描述高風險交會情境。互動特徵包含影像距離、地面距離、相對速度、CPA 與 TTC。影像距離指兩台車在影像座標中估計位置的距離，地面距離則是將車輛位置經 IPM 轉換到道路平面後計算的距離；相對速度描述兩車彼此接近或遠離的速度差。CPA (Closest Point of Approach) 表示預測期間兩車最接近距離，TTC (Time-to-Collision) 表示預測接近或碰撞所需時間。系統不會只因兩台車短暫接近就直接提高場景警示，而會要求兩台車在同一時

間內被連續觀測到足夠幀數、距離與相對速度變化連續合理，且 IPM 位置未落在影像邊界或投影誤差較大的區域。實作上，車對車互動通常需落在約 6 至 7.5 公尺的近距離範圍內，且 CPA 或 TTC 達到較嚴格門檻。互動判斷不是只看兩車目前距離，而是估計兩車在短時間內是否會更接近。CPA 可表示為

$$\begin{aligned} \hat{t} &= -\frac{\mathbf{r} \cdot \mathbf{v}}{\|\mathbf{v}\|^2}, \\ t^* &= \min(\max(\hat{t}, 0), T), \\ d_{\text{CPA}} &= \|\mathbf{r} + t^* \mathbf{v}\|. \end{aligned} \quad (12)$$

其中 $\mathbf{r}$ 為兩車在道路平面上的相對位置， $\mathbf{v}$ 為相對速度， T 為預測時間上限， d_{CPA} 為預測期間最近距離。 $\hat{t}$ 為未限制的最近接近時間， t^* 則將其限制在 0 到 T 之間，表示只考慮目前到預測時間上限內的接近情形。當相對速度接近零時，系統不以 CPA 提高場景警示，以避免分母過小造成不穩定估計。為降低誤報，系統不只檢查最近距離，也會排除只出現一兩幀、兩車相對位置大幅不連續變化、車輛幾乎靜止或 IPM 位置不穩定的情況。

場景最終輸出採混合式融合。若畫面中已有高風險車輛，整體場景警示不應低於該車輛風險；此作法是設定「整體場景警示的最低等級」，不是把某一台車的風險指定給同一視窗中的其他車輛。若模型欲將場景升為高風險，需符合明確交通條件，例如畫面中已有高風險單一車輛、同一時間存在多項異常，或兩車持續接近且 CPA/TTC 顯示可能形成交會危險。以下公式用於說明場景輸出的融合邏輯，實作時仍會檢查時間窗完成、互動距離、相對運動與短期穩定性。

令 s 表示一個 scene window， $\mathcal{V}_s$ 表示該 window 中已完成單一車輛風險對齊的車輛集合， $R_{\text{single}}(i)$ 表示第 i 台車對外輸出的單一車輛風險等級。風險等級以數值表示，0、1、2 分別代表無風險、中風險與高風險。單一車輛風險下限定義為

$$R_{\text{floor}}(s) = \max_{i \in \mathcal{V}_s} R_{\text{single}}(i), \quad (13)$$

其中 $\max$ 表示取該 scene window 內所有已對齊車輛中的最高風險等級；若 $\mathcal{V}_s$ 為空，則 $R_{\text{floor}}(s)$ 設為無風險。式 (13) 只決定場景警示最低不得低於畫面中已完成對齊車輛的最高風險，不表示該車風險會傳遞給其他車輛。

為簡化表示，令 $R_L(s)$ 為場景模型依車輛摘要與場景統計輸出的風險等級， $R_F(s) = R_{\text{floor}}(s)$ 為單一車輛風險下限， $R_I(s)$ 為車對車互動條件達成時給予的場景風險等級。 $R_I(s)$ 只有在兩車距離夠近、相對速度顯示正在接近，且 CPA 或 TTC 達到互動警示門檻時才會提高。整體場景風險可概念化為

$$R_{\text{scene}}(s) = \max(R_L(s), R_F(s), R_I(s)), \quad (14)$$

式 (14) 中的最大值運算，是在三個場景風險來源的等級之間取最高者，而不是對車輛特徵向量取最大值。

也就是說，單一車輛風險提供的是場景警示下限，而非車與車之間的風險傳遞規則。本研究目前以場景層級互動條件進行融合，更細緻的逐車對互動建模則留待後續研究。

3.8 主動安全預警策略

最終預警輸出分為無風險、中風險與高風險。無風險表示尚未偵測到足以觸發警示的交通狀態；中風險表示用路人應提高注意並暫緩通行；高風險表示應停止通行或退回安全區。在應用上，三個等級可對應至綠燈、黃燈與紅燈警示。系統不以行人位置作為輸入，而是依據危險車輛與整體交通狀態觸發警示。

4. 實驗設計與結果分析

4.1 資料來源與標註轉換

由於真實道路中高風險行車事件較難大量取得，也不適合刻意製造危險情境，本研究以台灣雲林縣虎尾鎮林森路周邊道路作為模擬示範場域。資料產生流程以 OpenStreetMap 取得路網 [18]，再使用 SUMO 產生車流與軌跡 [19]，最後以 CARLA 渲染道路、車輛外觀與虛擬攝影機影像 [20]。影像前端將影片轉為幀編號、track ID、邊界框、偵測信心、車輛類別與號誌狀態等結構化資料，再結合道路幾何設定形成超速、闖紅燈與異常軌跡等交通行為資訊。實驗結果應解讀為模擬場域下的系統驗證，後續仍需以更多真實道路影像進行外部驗證。

人工標註分為單一車輛與場景兩個層級。前者記錄某台車在特定幀區間內的風險等級，並轉換成 ID window 標籤；後者記錄同一全域時間區間內的整體警示等級，並轉換成 scene window 標籤。

原始人工標註以四個等級輔助判斷。等級 0 表示未觀察到明確異常；等級 1 表示輕微壓線、短暫偏移或低幅度超速；等級 2 表示逆向、蛇行、闖紅燈或中度超速等單一明確異常；等級 3 表示多項異常，或穩定超過速限 40 km/h 的高風險超速。由於等級 0 與 1 對主動預警而言皆不需觸發明確警示，本研究將兩者合併為「無風險」，最終使用無風險、中風險與高風險三類。

當人工標註區間與模型時間窗不完全重合時，本研究以幀重疊比例決定 window 標籤，並額外回報預警起點導向評估。後者只處理風險剛在窗尾形成且後續持續的少數邊界 window。以單一車輛固定切分為例，受影響比例約為 0.45%，表示此評估並非大幅重寫標籤，而是補充反映預警啟動時間。

4.2 評估設定

本研究以無風險、中風險與高風險三個預警等級進行評估。資料切分包含 train (訓練集)、val (validation set, 驗證集) 與 test (test set, 測試集)。單一車輛風險回報 window-level (時間窗) 與 track-level (整條車輛軌跡) 結果；場景風險回報 scene window-level 結果。評估指標包含準確率、各類別 F1 與 Macro F1。Macro F1 為各類別 F1 的算術平均，可避免無風險樣本數過多時掩蓋中風險與高風險類別的辨識情形 [14]；場景模組

中的嚴重度 Macro F1 為三個場景風險等級之 F1 平均。

固定切分的資料規模整理於表4。單一車輛風險模組每條軌跡最多包含 113 個 ID window，每窗為 16 維語意特徵。特徵標準化的平均值與標準差僅由 train 資料計算，val 與 test 不參與統計，以避免資料洩漏。

表 4. 固定切分 train、val 與 test 資料規模

模組與單位	train	val	test
單一車輛 track 數	2778	630	575
單一車輛最大 ID window 數	113	113	113
單一車輛每窗特徵維度	16	16	16
scene window 數	11749	2330	2367

表4中的 scene window 數為排除與標註區間重疊比例過低的邊界窗後，可用於評估的樣本數。

在預警起點導向評估下，val 與 test 的類別分布如表5所示。window-level 表示 ID window 數，track-level 表示整條車輛軌跡數。由於無風險樣本明顯較多，本研究除準確率外，主要回報各類別 F1 與 Macro F1。

表 5. 單一車輛風險模組 val 與 test 類別分布

統計單位	切分	無風險	中風險	高風險
ID window 數	val	13156	398	338
ID window 數	test	11490	311	583
track 數	val	558	28	44
track 數	test	487	15	73

本研究同時回報固定切分與 video-level 5-fold。前者呈現已整理資料上的主要效果；後者以影片為單位重新分配 train、val 與 test，用於檢查不同影片分布下的穩定性。除原始人工標註轉換外，本研究也回報預警起點導向評估，用於分析窗尾風險已形成但多數幀仍屬前一等級的邊界情形，並非模型推論時額外取得的資訊。

4.3 單一車輛風險結果

表6整理單一車輛風險模組在 test 上的主要結果。val 用於模型選擇與設定確認，不列入最終成績。固定切分列出單一 test 結果，video-level 5-fold 則列出各 fold test 結果的平均值與標準差。

表 6. 單一車輛風險模組 test Macro F1 (各類別平均 F1) 結果

資料切分	訓練與評估標籤	window-level	track-level
固定切分	train: 原始標註	0.9636	1.0000
	eval: 原始標註		
	train: 原始標註	1.0000	1.0000
	eval: 預警起點導向		
	train: 預警起點導向	0.9840	1.0000
	eval: 預警起點導向		
video-level 5-fold	train: 原始標註	0.8894±0.0084	0.9227±0.0417
	eval: 原始標註		
	train: 原始標註	0.9068±0.0106	0.9211±0.0401
	eval: 預警起點導向		

固定切分結果顯示，在已整理的資料切分下，系統輸出可高度對應人工風險標註，但不代表已能泛化

至各種影片或真實道路。train 與 eval 皆採預警起點導向者為對照實驗，用於觀察同一標籤口徑下的表現。video-level 5-fold 的分數較低，主因是中風險常受標註邊界、短暫超速、正常轉彎與蛇行邊界，以及 ID window 起始時間影響。track-level 結果通常高於 window-level，因為前者只檢查整條車最高風險是否被辨識。

4.4 場景風險結果

表7列出場景風險模組的 test 結果。場景模組對於無風險與高風險較穩定，中風險較容易受到 window 邊界、單一車輛風險起始時間與車對車互動連續性的影響。

表 7. 場景風險模組 test F1 結果

切分	Macro F1	無風險 F1	中風險 F1	高風險 F1
test	0.9339	0.9812	0.8674	0.9531

代表案例顯示，高風險常來自畫面內已有高風險單一車輛、車對車接近或交會路徑，以及多台車同時需要提高警示。較細緻的車對車互動特徵雖有助於解釋特定案例，但在 val 上仍不夠穩定，因此未納入最終方法。

5. 結論與未來工作

本研究提出影像式多語意模組融合的交通風險評估與主動安全預警框架。相較於僅以單一違規觸發警示的方法，本研究將車輛偵測、追蹤與號誌資訊轉換為超速、闖紅燈與異常軌跡等可解釋交通語意，再整合單一車輛與場景層級風險。

實驗結果顯示，單一車輛風險在固定切分下可有效對應人工標註，video-level 5-fold 亦提供跨影片切分下的穩定性檢查；場景風險模組在固定切分 test 中達到 0.9339 的嚴重度 Macro F1，顯示多語意與多車資訊融合可用於整體預警判斷。

目前限制包含資料主要來自模擬示範場域、場景風險尚未完成 scene-level 5-fold，以及尚未進行實體警示裝置、行人反應與完整即時延遲實驗。後續將擴充真實道路資料、補充道路幾何與多語意特徵的消融實驗，並評估四分類輸出與實體警示裝置整合。

致謝

本研究感謝國科會計畫補助，計畫編號為 NSTC 114-2637-E-150-014。

參考文獻

- [1] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, "You only look once: Unified, real-time object detection," in 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016, pp. 779–788.
- [2] A. Bochkovskiy, C.-Y. Wang, and H.-Y. M. Liao, "Yolov4: Optimal speed and accuracy of object detection," arXiv preprint arXiv:2004.10934, 2020.
- [3] N. Wojke, A. Bewley, and D. Paulus, "Simple online and real-time tracking with a deep association metric," in 2017 IEEE International Conference on Image Processing (ICIP), 2017, pp. 3645–3649.

- [4] Y. Zhang, P. Sun, Y. Jiang, D. Yu, F. Weng, Z. Yuan, P. Luo, W. Liu, and X. Wang, "Bytetrack: Multi-object tracking by associating every detection box," in European Conference on Computer Vision. Springer, 2022, pp. 1–21.
- [5] C. Piciarelli, C. Micheloni, and G. L. Foresti, "Trajectory-based anomalous event detection," IEEE Transactions on Circuits and Systems for Video Technology, vol. 18, no. 11, pp. 1544–1554, 2008.
- [6] Y. Cai, H. Wang, X. Chen, and H. Jiang, "Trajectory-based anomalous behaviour detection for intelligent traffic surveillance," IET Intelligent Transport Systems, vol. 9, no. 8, pp. 810–816, 2015.
- [7] S. W. Khan, Q. Hafeez, M. I. Khalid, R. Alroobaea, S. Hussain, J. Iqbal, J. Almotiri, and S. S. Ullah, "Anomaly detection in traffic surveillance videos using deep learning," Sensors, vol. 22, no. 17, p. 6563, 2022.
- [8] J. Fang, J. Qiao, J. Xue, and Z. Li, "Vision-based traffic accident detection and anticipation: A survey," IEEE Transactions on Circuits and Systems for Video Technology, vol. 34, no. 4, pp. 1983–1999, 2024.
- [9] M. M. Minderhoud and P. H. L. Bovy, "Extended time-to-collision measures for road traffic safety assessment," Accident Analysis & Prevention, vol. 33, no. 1, pp. 89–97, 2001.
- [10] N. Kronprasert, C. Sutheerakul, T. Satiennam, and P. Luthathep, "Intersection safety assessment using video-based traffic conflict analysis: The case study of thailand," Sustainability, vol. 13, no. 22, p. 12722, 2021.
- [11] K. Cho, B. van Merriënboer, C. Gulcehre, D. Bahdanau, F. Bougares, H. Schwenk, and Y. Bengio, "Learning phrase representations using rnn encoder–decoder for statistical machine translation," in Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP), 2014, pp. 1724–1734.
- [12] B. Wang, W. Li, and Z. H. Khattak, "Anomaly detection in connected and autonomous vehicle trajectories using lstm autoencoder and gaussian mixture model," Electronics, vol. 13, no. 7, p. 1251, 2024.
- [13] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollár, "Focal loss for dense object detection," in Proceedings of the IEEE International Conference on Computer Vision, 2017, pp. 2980–2988.
- [14] M. Sokolova and G. Lapalme, "A systematic analysis of performance measures for classification tasks," Information Processing & Management, vol. 45, no. 4, pp. 427–437, 2009.
- [15] L. Prechelt, "Early stopping – but when?" in Neural Networks: Tricks of the Trade, G. B. Orr and K.-R. Müller, Eds. Berlin, Heidelberg: Springer, 1998, pp. 55–69.
- [16] M. Zaheer, S. Kottur, S. Ravanbakhsh, B. Poczos, R. Salakhutdinov, and A. J. Smola, "Deep sets," in Advances in Neural Information Processing Systems, vol. 30, 2017.
- [17] C. R. Qi, H. Su, K. Mo, and L. J. Guibas, "Pointnet: Deep learning on point sets for 3d classification and segmentation," in Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2017, pp. 652–660.
- [18] M. Haklay and P. Weber, "Openstreetmap: User-generated street maps," IEEE Pervasive Computing, vol. 7, no. 4, pp. 12–18, 2008.
- [19] P. A. Lopez, M. Behrisch, L. Bieker-Walz, J. Erdmann, Y.-P. Flötteröd, R. Hilbrich, L. Lücken, J. Rummel, P. Wagner, and E. Wießner, "Microscopic traffic simulation using sumo," in 2018 21st International Conference on Intelligent Transportation Systems (ITSC), 2018, pp. 2575–2582.
- [20] A. Dosovitskiy, G. Ros, F. Codevilla, A. Lopez, and V. Koltun, "Carla: An open urban driving simulator," in Proceedings of the 1st Annual Conference on Robot Learning, 2017, pp. 1–16.